

ОЛИМПИАДА ШКОЛЬНИКОВ
«УНИВЕРСИТЕТ ЦИФРОВОЙ ПОЛИЦИИ»
по информационной безопасности

ПРОЕКТ

По направлению:

«Использование открытых информационных ресурсов для поиска информации в сети Интернет при противодействии преступности»

Тема проекта:

«Восстановление удаленных метаданных из фотографий, сжатых алгоритмами мессенджеров»

Выполнила:

Фамилия: Невская

Имя: София

Отчество: Станиславовна

Школа: Гимназия №1 ОГУ им. И.С. Тургенева

Класс/курс 11

- Направление проекта

Использование открытых информационных ресурсов для поиска информации в сети Интернет при противодействии преступности

- Название проекта

Восстановление удаленных метаданных из фотографий, сжатых алгоритмами мессенджеров

- Аннотация

Проект посвящен исследованию воздействия алгоритмов сжатия популярных мессенджеров на метаданные цифровых фотографий (EXIF) и разработке программного инструмента для извлечения остаточной информации из таких изображений.

EXIF-метаданные являются «цифровым паспортом» фотографии и содержат важную информацию: GPS-координаты, модель устройства, дату и время съемки.

Основная проблема проекта: потеря таких при сжатии в мессенджерах и недостаток инструментов для их восстановления.

Цель проекта: разработать специализированный Telegram-бот, позволяющий сотрудникам правоохранительных органов извлекать максимально возможный объем метаданных из фотографий, прошедших через алгоритмы сжатия мессенджеров, для последующего использования в качестве ориентирующей информации.

Задачи:

- Проанализировать механизмы сжатия изображений в мессенджерах;
- Классифицировать EXIF-данные по устойчивости к сжатию;
- Исследовать методы восстановления поврежденных EXIF-структур;

- Разработать алгоритм и ПО (бэкенд) для извлечения метаданных;
- Создать пользовательский интерфейс.

Методы исследования: изучение и обобщение, анализ, сравнение, тестирование.

- Теоретический блок

EXIF (англ. Exchangeable Image File Format) — стандарт метаданных, который позволяет добавлять к изображениям и прочим медиафайлам дополнительную информацию (метаданные).

Эти данные имеют ключевое значение в контексте противодействия преступности, так как они могут содержать следующую информацию:

- Модель и серийный номер камеры/телефона;
- GPS-координаты;
- Дату и время съемки.

Современные мессенджеры для экономии трафика и ускорения загрузки автоматически сжимают изображения. Этот процесс часто приводит к удалению или повреждению EXIF-данных. Исследования показывают, что алгоритмы сжатия работают по-разному, так например «WhatsApp» известен агрессивным сжатием, при отправке изображения как фото (не как документа) мессенджер конвертирует файл, как правило, полностью удаляя EXIF для экономии места, а «Telegram» при отправке как «фото» сжимает файл и часто «вычищает» метаданные, однако при отправке как «файл» он сохраняет оригинал нетронутым.

Современные мессенджеры, стремясь сократить трафик и ускорить загрузку, автоматически сжимают изображения. Это приводит к удалению или порче EXIF-данных. Алгоритмы сжатия различаются, так например «WhatsApp» известен агрессивным сжатием, при отправке изображения мессенджер конвертирует файл, как правило, полностью удаляя EXIF для

экономии места, «Telegram» при отправке без сжатия сохраняет оригинал нетронутым, при сжатии же большая часть метаданных повреждается. Наибольший интерес представляет случай, когда происходит сжатие, поскольку пользователи зачастую редко прибегают к опции отправки файла из-за более высокой скорости загрузки.

Даже после агрессивного сжатия существуют методы извлечения информации:

- Анализ JPEG: EXIF-блок (APP1) может сохраняться в "мусорных" областях файла.
- Различные библиотеки и глубина анализа: Разные программные библиотеки по-разному обращаются с битами или нестандартными EXIF-структурами. То, что не читает стандартный проводник Windows, может прочитать утилита `exiftool` или специализированный скрипт на Python. Использование нескольких парсеров последовательно повышает вероятность обнаружения сохранившихся фрагментов данных .
- В некоторых случаях мессенджеры оставляют превью (эскиз) изображения, который может содержать собственные миниатюрные EXIF-данные или даже фрагменты основного снимка.

Анализ существующих решений:

В ходе анализа открытых источников выявлены следующие инструменты :

- Существующие Telegram-боты (например, `@EXIF_foto_bot`) предназначены для извлечения открытых данных из несжатых изображений.
- Библиотеки (`exifread`, `PIL`) и утилиты (`exiftool`) используются по отдельности и не имеют единой надстройки, которая бы интерпретировала частично поврежденные данные.
- Существующие коммерческие продукты (например, `EXIFer Pro`), создающее фото- и видеоматериалы с защитными метаданными, защита которых обеспечивается за счёт того, что в момент

съёмки генерируется криптографический хеш (SHA-256) файла

- Практический блок

Основная идея, реализованная в проекте - концепция "многослойного сканирования":

- Первый слой: Мощные парсеры (ExifTool) — читают даже битые структуры
- Второй слой: Терпимые парсеры (ExifRead) — игнорируют ошибки формата
- Третий слой: Анализ миниатюр (Pillow) — данные могут сохраниться в превью
- Четвертый слой: Низкоуровневый разбор (Naschoir) — поиск в "мусорных" областях файла

Финальный этап:

Агрегатор собирает все найденные фрагменты, склеивает их и формирует единый отчет.

Архитектура реализованного решения:

- Модуль ввода (веб-дашборд):
 - Сайт состоит из следующих основных разделов:
 - Главная страница (Dashboard)
 - Архив ранее проведенных исследований
 - Сравнение изображений
 - Быстрый старт. Пошаговое руководство:
 - Перетащите изображение в область загрузки
 - Дождитесь завершения анализа (10-30 секунд)
 - Изучите результаты на вкладках
 - Экспортируйте отчет при необходимости
- Интерфейс позволяет пользователю:

- Быстро получить ориентирующую информацию (GPS, модель камеры)
 - Углубиться в детали при необходимости (сравнение парсеров)
 - Проверить достоверность результатов (хеши, HEX-дампы)
 - Экспортировать результаты в формате, пригодном для официальных документов
-
- Ядро форензики (Forensic Core) на Python. Это ключевой компонент, реализующий концепцию "многослойного сканирования. При получении файла ядро выполняет следующие шаги:
 - Прием и нормализация: Файл сохраняется во временное хранилище с вычислением хеш-суммы (SHA-256) для обеспечения неизменности улики.
 - Конвейер анализа:
 - Парсер 1 (ExifTool): Первым вызывается exiftool как наиболее мощное средство, способное читать данные даже из битых структур.
 - Парсер 2 (ExifRead): Если ExifTool не дал результата или дал частичный, начинает использоваться библиотека exifread.
 - Парсер 3 (PIL/Pillow): Анализирует встроенные миниатюры (thumbnails) на предмет наличия в них метаданных.
 - Парсер 4 (Hachoir): Библиотека hachoir-metadata используется для низкоуровневого разбора структуры файла и поиска сигнатур метаданных в нестандартных местах (например, после маркера окончания изображения).
 - Агрегатор и корректор: Данные от всех парсеров собираются, сравниваются и очищаются от дубликатов. Если один парсер

нашел GPS-координаты, а второй — только модель камеры, они объединяются в единый финальный профиль.

- Интерпретация GPS: Если координаты найдены, они конвертируются из формата EXIF (градусы/минуты/секунды) в десятичные и формируется ссылка на Яндекс.Карты или Google Maps для мгновенного просмотра местности.

Технический стек:

- Языки программирования: Python 3.12,
- Библиотеки: `exifread`, `Pillow`, `hachoir-metadata`, `subprocess` (для вызова `exiftool`).
- Фреймворк: `flask`
- Внешние утилиты: `ExifTool` (интегрируется в контейнер).

В приложении 1 приведен HTML-код веб-сайта, используемого в качестве пользовательского интерфейса.

В приложении 2 представлен код реализации ядра форензики на Python.

Код, представленный в приложениях 1 и 2, не является полным и достаточным для правильного функционирования разработанного инструмента.

- Заключение

В ходе реализации проекта были выполнены все поставленные задачи.

Разработанный продукт представляет собой первый шаг к созданию специализированного инструмента, учитывающего реалии цифрового обмена данными. В отличие от бытовых программ просмотра, он реализует агрессивную стратегию поиска остаточных данных, что позволяет извлекать максимум информации даже из файлов, прошедших через алгоритмы сжатия мессенджеров, пользовательский интерфейс отличается понятностью, доступностью, эффективностью и удобством в использовании

Были выявлены такие направления дальнейшего развития, как анализ видеофайлов, увеличение точности данных, улучшение пользовательского интерфейса, добавление новых функций.